



SVD矩阵分解

✓ 向量的表示及基变换

✎ 向量可以表示为(3,2)
实际上表示线性组合: $x(1,0)^T + y(0,1)^T$

✎ 基: (1,0)和(0,1)叫做二维空间中的一组基




SVD矩阵分解

✓ 基变换

✎ 基是正交的（即内积为0，或直观说相互垂直）

✎ 要求：线性无关



SVD矩阵分解

✓ 基变换

✎ 变换：数据与一个基做内积运算，结果作为第一个新的坐标分量，然后与第二个基做内积运算，结果作为第二个新坐标的分量


✎ 数据 (3, 2) 映射到基中坐标：
$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

SVD矩阵分解


✓ 矩阵乘以一个向量

✎ 结果仍是一个向量

$$\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3x \\ y \end{bmatrix}$$



$$M = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$



SVD矩阵分解

✓ 特征值分解

✎ 矩阵里面的信息有很多呀？来分一分吧！ $A = U\Lambda U^{-1}$ U: 特征向量
^: 特征值

✎ 当矩阵是N*N的方阵且有N个线性无关的特征向量时就可以来玩啦！

✎ 这时候我们就可以在对角阵当中找比较大的啦，他们就是代表了！


用于矩阵分解，矩阵近似，矩阵降维

SVD矩阵分解

✓ SVD

✎ 特征值分解不挺好的嘛，但是它被限制住了，如果我的矩阵形状变了呢？

✎ 但是问题也来了，如果M和N都很大呢？




SVD矩阵分解

✓ SVD

SVD用于特征压缩，特征降维；
推荐系统基于SVD提取主要信息

✎ 照样按照特征值的大小来进行筛选，一般前10%的特征值（甚至更少）的和就占到了总体的99%了。

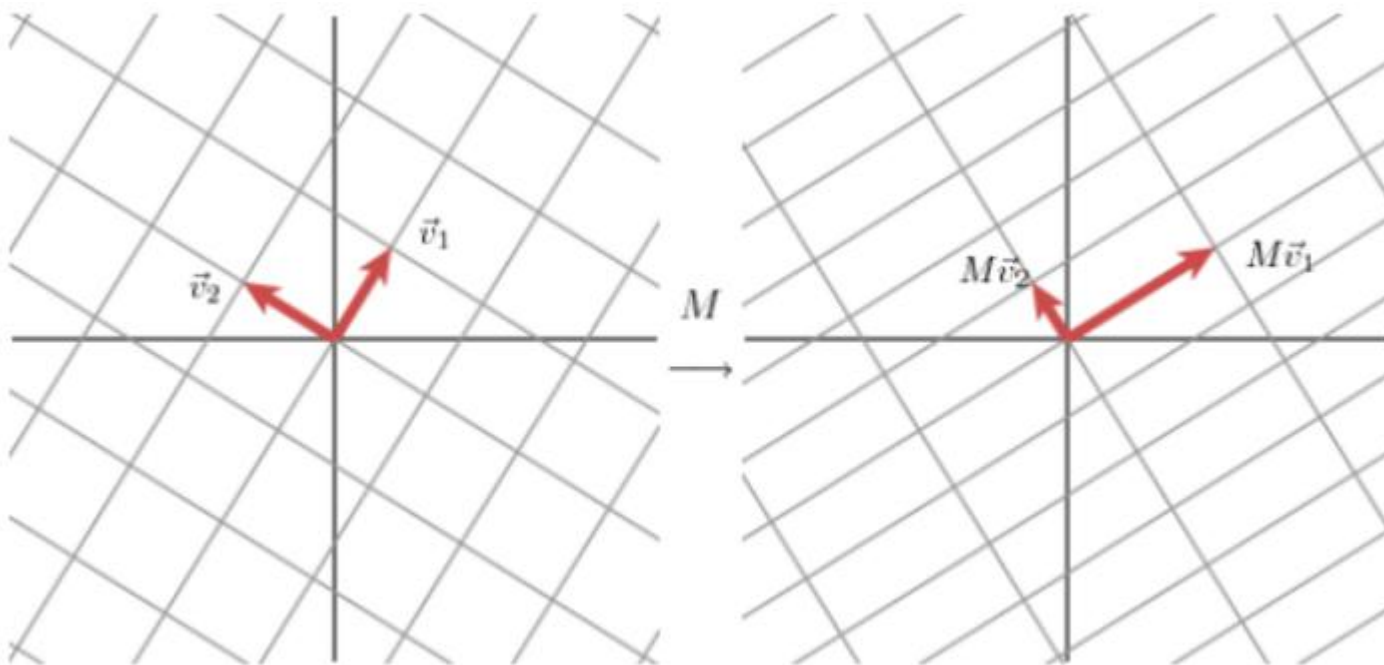
✎ 取前K个来看看吧！



SVD矩阵分解

✓ SVD推导

✎ 前提：对于一个二维矩阵 M 可以找到一组标准正交基 \vec{v}_1 和 \vec{v}_2 使得 $M\vec{v}_1$ 和 $M\vec{v}_2$ 是正交的。



SVD矩阵分解

✓ SVD推导

✎ 使用另一组正交基 u_1 和 u_2 来表示 Mv_1 和 Mv_2 的方向

✎ 其长度分别为: $\|MV_1\| = \sigma_1$, $\|MV_2\| = \sigma_2$ 可得: $MV_1 = \sigma_1 u_1$
 $MV_2 = \sigma_2 u_2$

✎ 对于向量 X 在这组基中的表示: $x = (v_1 \cdot x)v_1 + (v_2 \cdot x)v_2$
(点积表示投影的长度, 可转换成行向量乘列向量 $v \cdot x = v^T x$)

✎ 可得: $Mx = (v_1 \cdot x)Mv_1 + (v_2 \cdot x)Mv_2$ 从而: $Mx = u_1 \sigma_1 v_1^T x + u_2 \sigma_2 v_2^T x$ 化简得: $M = U \Sigma V^T$
 $Mx = (v_1 \cdot x) \sigma_1 u_1 + (v_2 \cdot x) \sigma_2 u_2$ $M = u_1 \sigma_1 v_1^T + u_2 \sigma_2 v_2^T$

